

SocialMetrics AI — Rapport d'évaluation du modèle

Analyse de sentiments des tweets — Régression logistique (TF-IDF)

Jeu de données annoté évalué : 27 tweets (table `tweets`).


Méthodologie :

- Deux classifieurs binaires indépendants (comme en production) : un pour la colonne `positive`, un pour la colonne `negative`.
- Évaluation par validation croisée stratifiée à 5 plis (positive) et 5 plis (negative), avec `cross_val_predict` : chaque tweet est prédit par un modèle qui ne l'a jamais vu à l'entraînement.
- Ce choix évite de sacrifier une grande partie d'un jeu de données restreint dans un simple split train/test, tout en gardant une évaluation honnête.

Ce rapport présente, pour chacune des deux classes (positive et negative) :

1. La matrice de confusion des prédictions,
2. Les métriques de précision, rappel et F1-score,
3. Une analyse des biais et erreurs observés,
4. Des recommandations d'amélioration.

Matrice de confusion — classe « positive »



Interprétation — Matrice de confusion « positive »

Vrais négatifs (VN) : 15 | Faux positifs (FP) : 0


Faux négatifs (FN) : 12 | Vrais positifs (VP) : 0

Le modèle identifie correctement 0 des 12 tweets réellement positifs (rappel classe positive = 0.00), et parmi les tweets qu'il annonce positifs, 0/0 le sont vraiment (précision classe positive = 0.00).

Précision / Rappel / F1-score — classe « positive »

Classe	Précision	Rappel	F1-score	Support
Non-positive (0)	0.56	1.00	0.71	15
Positive (1)	0.00	0.00	0.00	12

Matrice de confusion — classe « negative »



Interprétation — Matrice de confusion « negative »

Vrais négatifs (VN) : 16 | Faux positifs (FP) : 0

Faux négatifs (FN) : 11 | Vrais positifs (VP) : 0

Le modèle identifie correctement 0 des 11 tweets réellement négatifs (rappel classe negative = 0.00), et parmi les tweets qu'il annonce négatifs, 0/0 le sont vraiment (précision classe negative = 0.00).

Précision / Rappel / F1-score — classe « negative »

Classe	Précision	Rappel	F1-score	Support
Non-négative (0)	0.59	1.00	0.74	16
Négative (1)	0.00	0.00	0.00	11

Analyse des biais et des erreurs

- Biais majeur observé sur la classe « positive » : en validation croisée (donc sur des tweets que le modèle n'a jamais vus à l'entraînement), aucune prédiction ne dépasse le seuil de 0.5 (probabilités comprises entre 0.41 et 0.49, écart de seulement 0.08). Le modèle ne fait donc que reconnaître les tweets déjà mémorisés pendant l'entraînement et échoue à généraliser à de nouveaux tweets pour cette classe.

- Cause probable : avec seulement 27 tweets annotés et un vectoriseur TF-IDF autorisant jusqu'à 5000 features en unigrammes+bigrammes, l'espace des caractéristiques est bien plus grand que le nombre d'exemples. Chaque pli de validation entraîne le modèle sur un vocabulaire trop spécifique aux tweets vus, qui ne se retrouve pas forcément dans les tweets laissés de côté.

- Biais majeur observé sur la classe « negative » : en validation croisée (donc sur des tweets que le modèle n'a jamais vus à l'entraînement), aucune prédiction ne dépasse le seuil de 0.5 (probabilités comprises entre 0.35 et 0.47, écart de seulement 0.12). Le modèle ne fait donc que reconnaître les tweets déjà mémorisés pendant l'entraînement et échoue à généraliser à de nouveaux tweets pour cette classe.

- Cause probable : avec seulement 27 tweets annotés et un vectoriseur TF-IDF autorisant jusqu'à 5000 features en unigrammes+bigrammes, l'espace des caractéristiques est bien plus grand que le nombre d'exemples. Chaque pli de validation entraîne le modèle sur un vocabulaire trop spécifique aux tweets vus, qui ne se retrouve pas forcément dans les tweets laissés de côté.

- Les tweets du jeu de données sont courts (en moyenne 5.3 mots), ce qui limite le nombre de signaux lexicaux disponibles pour le TF-IDF et augmente le risque de confusion sur des formulations inhabituelles ou ironiques.

- Le jeu de données mélange français et anglais avec un vocabulaire globalement explicite (« terrible », « fantastique », « nul »...) ; des tweets plus subtils, sarcastiques ou implicites seraient probablement mal classés par ce vectoriseur purement lexical (TF-IDF), qui ne capture pas le contexte ou la négation à longue distance.

Recommandations d'amélioration

1. Priorité n°1 : augmenter significativement la taille du jeu de données annoté. Avec seulement ~27 tweets, le modèle ne parvient à prédire aucun cas positif hors échantillon (voir l'analyse des biais) — il faut au moins plusieurs centaines de tweets par classe avant d'attendre des performances fiables.
2. Réduire la dimensionnalité du TF-IDF pour ce volume de données (par ex. `max_features` réduit à quelques centaines, ou `ngram_range=(1,1)` le temps que le corpus grandisse) afin de limiter le sur-apprentissage sur un vocabulaire trop spécifique aux tweets d'entraînement.
3. Ajuster la régularisation (paramètre `C` de `LogisticRegression`) par validation croisée plutôt que de garder `C=1.0` par défaut, pour trouver le compromis biais/variance adapté à la taille réelle du jeu de données.
4. Ajouter une vraie classe « neutre » explicite dans la table ``tweets`` (aujourd'hui encodée implicitement par `positive=0` ET `negative=0`) pour éviter que le modèle ne confonde neutre et sentiment faible.
5. À terme, remplacer ou compléter le TF-IDF par des embeddings contextuels (ex. `sentence-transformers`) pour mieux capturer la négation, le sarcasme et le contexte au-delà du simple sac de mots.
6. Suivre les métriques (précision/rappel/F1) à chaque réentraînement hebdomadaire et déclencher une alerte si le F1 d'une classe chute, afin de détecter une dérive du modèle (data drift).
7. Mettre en place une revue humaine périodique d'un échantillon des tweets mal classés pour affiner les règles d'annotation et réduire les incohérences entre annotateurs.